



Universidade de Brasília

**Instituto de Ciências Exatas
Departamento de Ciência da Computação**

**Investigando o uso de bancos de dados não
convencionais para gerenciar informações da
administração pública**

Diogo Araújo Pacheco Wanzeller

Monografia apresentada como requisito parcial
para conclusão do Curso de Computação — Licenciatura

Orientador
Prof. Dr. Rodrigo Bonifacio de Almeida

Brasília
2013

Universidade de Brasília — UnB
Instituto de Ciências Exatas
Departamento de Ciência da Computação
Curso de Computação — Licenciatura

Coordenador: Prof. Dr. Flávio de Barros Vidal

Banca examinadora composta por:

Prof. Dr. Rodrigo Bonifacio de Almeida (Orientador) — CIC/UnB

Prof. Dr. Professor I — CIC/UnB

Prof. Dr. Professor II — CIC/UnB

CIP — Catalogação Internacional na Publicação

Wanzeller, Diogo Araújo Pacheco.

Investigando o uso de bancos de dados não convencionais para gerenciar informações da administração pública / Diogo Araújo Pacheco Wanzeller. Brasília : UnB, 2013.

107 p. : il. ; 29,5 cm.

Monografia (Graduação) — Universidade de Brasília, Brasília, 2013.

1. big-data, 2. NoSql, 3. Banco de Dados

CDU 004.4

Endereço: Universidade de Brasília
Campus Universitário Darcy Ribeiro — Asa Norte
CEP 70910-900
Brasília-DF — Brasil



Universidade de Brasília

**Instituto de Ciências Exatas
Departamento de Ciência da Computação**

**Investigando o uso de bancos de dados não
convencionais para gerenciar informações da
administração pública**

Diogo Araújo Pacheco Wanzeller

Monografia apresentada como requisito parcial
para conclusão do Curso de Computação — Licenciatura

Prof. Dr. Rodrigo Bonifacio de Almeida (Orientador)
CIC/UnB

Prof. Dr. Professor I Prof. Dr. Professor II
CIC/UnB CIC/UnB

Prof. Dr. Flávio de Barros Vidal
Coordenador do Curso de Computação — Licenciatura

Brasília, 28 de janeiro de 2013

Dedicatória

Dedico a....

Agradecimentos

Agradeço a....

Abstract

A ciência...

Palavras-chave: big-data, NoSql, Banco de Dados

Abstract

The science...

Keywords: big-data, NoSql, Data Bases

Sumário

1	Introdução	1
2	Big Data	4
2.1	O que é Big Data?	4
2.2	Tecnologias de Apoio	5
2.2.1	Bases Relacionais	5
2.2.2	Bases Não Relacionais	8
3	NoSql	11
3.1	Definição de NoSQL	11
3.2	História	11
3.3	Os Principais Tipos de Banco de Dados NoSql	12
3.3.1	Chave-Valor	12
3.3.2	Orientados a Documentos	12
3.3.3	Orientados a Colunas	13
3.3.4	Baseados em Grafos	14
3.4	MongoDB	14
3.4.1	Modelagem dos Dados	15
3.4.2	Linguagem de Consulta	17
3.4.3	Replicação	17
3.4.4	Decomposição (Sharding)	18
3.4.5	Tratamento de Falhas	18
4	Testes	22
4.1	Definição	22
4.2	Teste de Software e Qualidade de Software	22
4.3	Tipos de Testes	23
4.3.1	Aplicados a cada estágio de teste	23
4.3.2	Estágios (ou Níveis) de teste	24
4.3.3	Outros tipos de testes	24
4.4	Testes de Carga e de Performance	25
4.4.1	Testes de carga	25
4.4.2	Teste de Performance	25
4.5	Automação de Testes	26
4.6	JMeter	27
4.6.1	Testador	28
4.6.2	Ouvintes	29

4.6.3	Elemento de Configuração	29
5	Web-Service	31
5.1	O que é web-service?	31
5.2	Componentes de um Web-Service	31
5.2.1	SOAP	31
5.3	WSDL	33
5.4	UDDI	34
6	O Projeto	35
6.1	A Aplicação	35
6.2	A Arquitetura do Projeto	35
6.2.1	web2py	38
6.3	Os Planos de Teste	38
6.3.1	Planos de Teste de Inserção	39
6.3.2	Planos de Teste de Consulta	40
7	Execução dos Testes	41
7.0.3	Ambiente de testes	41
7.0.4	Massa de Dados	41
7.0.5	Métricas	42
7.0.6	Resultados	42
	Referências	43

Lista de Figuras

1.1	Evolução do HD [4]	2
2.1	Modelo Relacional	6
2.2	Teorema CAP [18]	8
2.3	Consistência Forte: O processo A, B e C sempre estão vendo a mesma versão do banco de dados [27].	9
2.4	Consistência Eventual: Os processos A, B e C podem visualizar diferentes versões dos dados durante a janela de inconsistência causada pela replicação assíncrona [27].	10
3.1	Modelagem orientada a colunas	13
3.2	Documento BSON usado no MongoDB [5]	15
3.3	Modelagem utilizando referência. Adaptado de [5]	16
3.4	Modelagem utilizando sub-documento. Adaptado de [5]	17
3.5	Arquitetura de Replicação [5]	18
3.6	Cluster de Sharding [5]	19
4.1	TestLink - acompanhamento/suporte [10]	26
4.2	JMeter - Ferramenta para execução de testes [1]	27
4.3	Testador de Requisição SOAP/XML - RPC	28
4.4	Elemento de Configuração de Dados CSV	30
6.1	Modelo de Casos de Uso	36
6.2	Descrição dos Métodos	36
6.3	Arquitetura de Testes	38

Lista de Tabelas

2.1	Tabela de bytes	5
3.1	BSON - Tipos Suportados	14
3.2	Declarações SQL vs Declarações MongoDB. Adaptado de [5]	20
3.3	SQL Select vs MongoDB Select. Adaptado de [5]	21
4.1	Tipos de teste e sua característica de qualidade correspondente	23
5.1	Elementos de um documento WSDL	33
6.1	Descrição das Funcionalidades	37
6.2	Principais configurações dos Planos de Teste	39

Capítulo 1

Introdução

A sociedade está lidando com uma quantidade de dados cada vez maior. Hoje, por menor que seja o dado, ele se torna importante pelas informações que podem ser extraídas a partir dele. Se pararmos para pensar, estamos envolvidos por uma quantidade de dados enorme. Como a necessidade de extrair informação é comum em um mundo globalizado e informatizado, os cientistas e engenheiros se veem obrigados a desenvolver novas maneiras de medir eventos. Sensores, câmeras de trânsito, dados da web, genes, dados geográficos, dados de compras, dados de pesquisas, e muitas outras informações se tornaram o diferencial nesse mundo competitivo e dinâmico, e precisam de tratamento e atenção [16]. Conforme Borkar et al [13] exemplificou, hoje empresas estão monitorando compras de clientes, pesquisas de produtos, sites de relacionamento e diversas outras fontes para aumentar a eficácia do seu marketing e dos serviços ofertados aos clientes, que cada vez mais precisam ser diferenciados e inovadores; governos e empresas estão rastreando conteúdos de blogs e tweets para realizar análises de sentimentos e organizações públicas de saúde estão monitorando artigos de notícias, tweets, e tendências de pesquisas na web para acompanhar o progresso de epidemias [13]. Essa enorme quantidade de dados já gerou, e ainda gera, muitos desafios para cientistas e estudiosos. Não é de hoje que o mundo da TI vem enfrentando grandes problemas com essa grande e heterogênea massa de dados.

No decorrer da evolução dos computadores e com a informatização do mundo, podemos perceber que, ao longo do tempo, a definição de “grande” foi mudando significativamente. Na figura 1.1 podemos ter uma idéia dessa evolução. Poucos anos atrás falar em terabytes era coisa de outro mundo, e atualmente a grande maioria das pessoas já possuem dispositivos de armazenamento com capacidade superior a um terabyte. Hoje, para as grandes empresas, já é normal gravar dados na ordem de petabytes (Tabela 2.1).

Como exemplo podemos citar a administração pública, que possui um grande volume de documentos que precisam ser armazenados com qualidade e cuidado, pois fazem parte dos chamados arquivos permanentes. Esses arquivos ocupam cada vez mais espaço e, devido a sua característica, precisam ser mantidos em locais próprios e com características bem definidas, já que precisam durar por um longo período de tempo. Inúmeras vezes os órgãos precisam consultar esses arquivos e essas consultas, além de contribuírem para a deteriorização dos documentos, são muitas vezes lentas e difíceis de se realizar [8].

A dificuldade de manter esses papéis fez com que o governo federal incentivasse a organização pública a iniciar um processo de digitalização dos documentos para que uma



Figura 1.1: Evolução do HD [4]

cópia digital desse arquivos fosse mantida pelos órgãos. A digitalização dos arquivos não só possibilita a preservação dos documentos, pois restringe o manuseio dos originais, quanto também facilita o acesso, já que passa a permitir acessos tanto locais quanto remotos e também acessos simultâneos. O processo de digitalização é complexo, demorado e, além de um controle de work flow bem definido, necessita de grandes investimentos de software e hardware para que o resultado tenha uma boa qualidade [8].

Como podemos ver, as finalidades da extração desses dados são diversas e podemos retirar informações preciosas dos dados que nos cercam, mas isso nem sempre é trivial e muitas vezes envolve muita tecnologia e estudo. Hoje, além de lidarmos com uma grande quantidade de dados, as vezes nos deparamos com dados que possuem grande variedade e fluxo. Essa massa de dados com características singulares é chamada de big data.

Podemos dividir as tecnologias que sustentam big data em duas: as envolvidas com análise dos dados, como Hadoop e MapReduce e tecnologias de armazenamento e processamento dos dados [30]. Na parte de armazenamento podemos citar os bancos de dados NoSql (Not only SQL), que surgiram a partir da necessidade de inovar no que diz respeito ao armazenamento de big data e distribuição de dados.

Dado esse cenário, os SGBDs relacionais não foram capazes de resolver todos os problemas e com o surgimento desse novo paradigma de modelagem, os sistemas de banco de dados NoSql estão sendo cada vez mais utilizados. Como essa tecnologia não-relacional é relativamente recente, existem poucos estudos comparativos que mostre em qual cenário se aplica o uso de uma tecnologia NoSql e até que ponto ela é melhor que um banco de dados convencional.

Esse trabalho surgiu de uma dúvida arquitetural para a implementação de um sistema que armazenasse todos os dados de servidores públicos federais. Como dito anteriormente, o governo tem orientado os órgãos a digitalizarem os seus arquivos e essa orientação fez com que os órgão se juntassem, devido ao elevado custo para implementação, para darem início a essa conversão dos arquivos físicos em digitais.

O conceito de documentos descentralizados em pastas funcionais será substituído por repositórios de dados e informações de origem primária, auditáveis e não replicados. Com isso teve origem o Projeto de Assentamento Funcional Digital – AFD, que objetiva a criação de um Dossiê, em mídia digital, que será tratado como Fonte Primária de Informação de dados cadastrais do Servidor Público Civil Federal e que substituirá a tradicional Pasta Funcional ou Assentamento Funcional. No site do SIGEPE (Sistema de Gestão de Pessoas) [9] alguns pontos de melhoria com a criação do AFD como: “A criação do Assentamento Funcional Digital (AFD) possibilitará a diminuição drástica do volume de papéis armazenados e tramitados. O AFD constituirá de um banco referencial, de dados e imagens das pastas funcionais, com indexadores para localização dos documentos de maneira online” [2].

Para que a base de dados possa cumprir com o seu propósito, ela precisa ter um alto nível de performance, e também, grande escalabilidade. Sendo assim, esse trabalho tem como objetivo analisar a diferença de performance entre bancos de dados NoSql e um banco de Dados Relacional para a gerência dos dados dos servidores públicos.

Para cumprir esse objetivo, desenvolveremos um webservice que possua métodos simples de inserção, consulta, exclusão e atualização de dados. A camada de persistência será implementada em diferentes SGBDs. Testaremos o desempenho da nossa aplicação usando um banco de dados relacional e compararemos o resultado com o de quatro bancos de dados NoSQL com diferentes tipos de modelagem.

Capítulo 2

Big Data

A quantidade de informação que está disponível para a humanidade é enorme e a medida que o conhecimento humano se expande, maior é a quantidade dessa informação que precisa ser armazenada e analisada. Além da quantidade, o fluxo e variedade dessas informações constantemente desafiam a indústria e a academia a medida em que a quantidade de Big Data aumenta exponencialmente. Nesse capítulo veremos uma definição detalhada de o que é Big Data, as tecnologias que apoiam esse domínio.

2.1 O que é Big Data?

Em um estudo divulgado em 2011 o tamanho do universo digital quebrou a barreira dos zettabytes e esse número está crescendo rapidamente [3]. Cientistas de diversas áreas estão vendo o grande potencial de conhecimento que se pode adquirir pela análise a armazenamento de informação digital. Conforme já dito anteriormente o conceito de 'grande (big)' foi mudando no decorrer da nossa história. Na década de 70, grande significava megabytes; ao longo do tempo cresceu para gigabytes e em seguida, a terabytes. Atualmente já podemos dizer que grande é petabyte e até mesmo exabytes [13]. Contudo o conceito de Big Data não se dá somente por tamanho ou domínio, mas sim por um conjunto de características que o difere de uma base de dados comum.

Segundo Gartner big data é definido, em geral, como uma massa de dados de grande volume, velocidade e variedade de informações que exigem formas inovadoras de processamento para maior visibilidade e tomada de decisão [19]. A maioria dos estudiosos compartilham dessa mesma definição e dizem que Big Data é caracterizado por no mínimo três V's. Volume, variedade e velocidade. [25, 29]

Volume é a característica mais fácil de se perceber. Geramos enormes quantidades de dados todos os dias, e essa quantidade só tende a aumentar. Redes sociais, dispositivos móveis que guardam nossas informações, sites que armazenam nossas preferências, dispositivos de busca que indexam as páginas da web e a popularização da computação em nuvem nos colocam em uma época de grande volume de dados, uma época em que tudo é informação, tudo é valioso, tudo pode ser extraído. Cada dia fica mais comum grandes empresas terem de lidar com dados na ordem de petabytes. Variedade é outra característica que é de fácil percepção, pois os dados são de diversas naturezas como email, dados gerados por mídias sociais (blogs, Twitter, Youtube, Facebook, Wikis), documentos eletrônicos, apresentações, fotos, mensagens instantaneas, dados médicos, videos, etc. A

Tabela 2.1: Tabela de bytes

Nome	Tamanho	Abreviação
Kilobyte	10^3	KB
Megabyte	10^6	MB
Gigabyte	10^9	GB
Terabyte	10^{12}	TB
Petabyte	10^{15}	PB
Exabyte	10^{18}	EB
Zettabyte	10^{21}	ZB
Yottabyte	10^{24}	YB

característica de velocidade é explicada quando precisamos processar os dados praticamente em tempo real como em controle de tráfego, detecções de fraudes e propagandas dinâmicas na web. Os dados são cada vez mais usados para tomadas de decisão em tempo real [12].

Dada a problemática do armazenamento, ao se deparar com os limites de técnicas e ferramentas disponíveis o mercado tratou de criar suas próprias soluções de gerenciamento de dados, em sua maioria não relacional. Usando a tecnologia apropriada, profissionais capacitados podem transformar grandes massas de dados em informações muito valiosas. Muitos sistemas comerciais relacionais se dizem capazes de lidar com vários petabytes de base de dados (Greenplum, Netezza, Teradata, ou Vertica). Apesar dessa quantidade de dados atender a grande maioria das empresas, existem empresas de grande porte como o Google e o Facebook que não são atendidas e precisaram criar suas próprias soluções, além disso, sistemas open source como Postgres não tem o mesmo nível de escalabilidade que os comerciais [25].

2.2 Tecnologias de Apoio

2.2.1 Bases Relacionais

Quando pensamos em armazenamento de dados em SGBDs logo associamos essa idéia ao método tradicional que inclui bancos de dados como MySQL, PostgreSQL, modelagem relacional e esquemas de dados bem definidos. O modelo de dados relacional foi introduzido por Ted Codd, da IBM Research, em 1970, em um artigo que conseguiu atrair grande atenção devido a simplicidade e base matemática. Os SGBDs relacionais mais populares atualmente são o DB2 e Informix Dynamic Server (IBM), o Oracle e Rdb (Oracle), o Sybase SGBD (Sybase) e o SQLServer e Access (Microsoft). Ainda temos os de código aberto como o MySQL e PostgreSQL.

O modelo relacional representa o banco de dados como uma coleção de relações 2.1. Uma relação é como se fosse uma tablea de valores ou um arquivo de registros. Cada tabela é formada por uma ou mais colunas de dados. Por sua vez, cada linha na tabela contém uma instância única de dado para as categorias de colunas definidas. No modelo

relacional é possível criar conexões entre as tabelas e os campos e os formatos dos valores são bem definidos, ou seja, possui um schema de dados [17, 24].

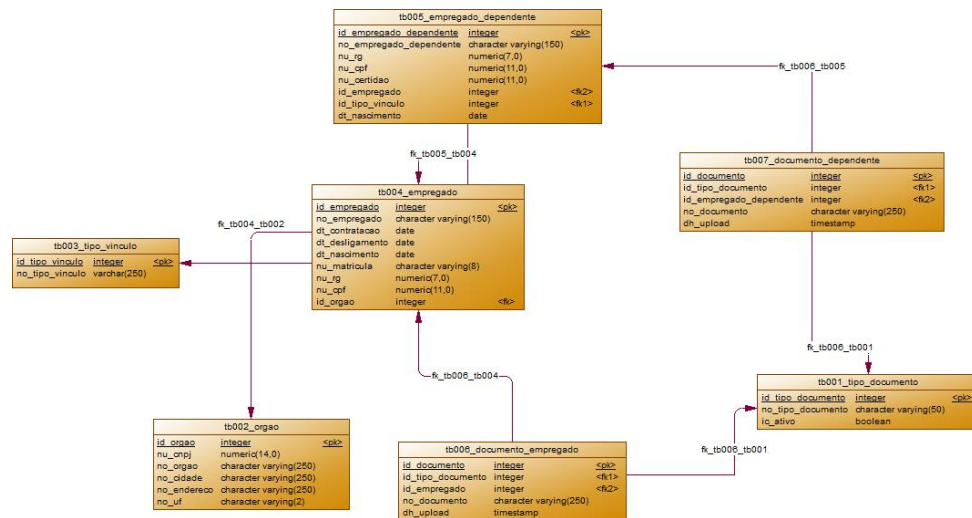


Figura 2.1: Modelo Relacional

Um das características mais importantes das bases de dados relacionais são as garantias das propriedades ACID [27]. ACID é um acrônimo para Atomicity (Atomicidade), Consistency (Consistência), Isolation (Isolamento) e Durability (Durabilidade).

Atomicidade: Significa que todas as etapas de uma transação serão executadas, caso contrário a transação será abortada sem interferir no banco de dados.

Consistência: Significa que um banco de dados estará em um estado consistente antes e após cada transação. Caso as mudanças de uma transação violem a regra de consistência, então todas as mudanças serão revogadas para garantir que somente os dados realmente válidos serão escritos no banco de dados.

Isolamento: significa que as transações não podem visualizar as mudanças que não foram submetidas ao banco. Como as alterações que resultaram em erros.

Durabilidade: Requer que os dados sejam escritos no banco antes de a transação ser confirmada. Caso haja uma falha de energia os dados não serão perdidos.

Os SGBDs (Sistemas Gerenciadores de Banco de Dados) relacionais proveem diversas garantias aos seus usuários como: validação, verificação e garantias de integridade dos dados, controle de concorrência, recuperação de falhas, entre outros. Todas essas características mantêm os SGBDs como principal solução na maioria dos ambientes computacionais, mas não impediram o surgimento de problemas, em alguns casos, causados pela rígida estrutura definida pelo layout das tabelas, nomes e tipos das colunas.

As abordagens mais usadas para manipular grandes bases nesse tipo de estrutura são os data warehouses e data marts. Um data warehouse é um banco de dados relacional usado para armazenar, analisar e gerar relatórios sobre os dados. O data mart é a camada usada para acessar o data warehouse. As duas abordagens usadas para se armazenar dados em um data warehouse são a normalização e a modelagem dimensional [11].

Limitações

Com a evolução das aplicações e com requisitos cada vez mais exigentes, foram surgindo casos em que os bancos de dados relacionais não escalavam. Operações de joins estão presentes nos menus dos bancos de dados relacionais, e esse tipo de operação é lenta. Para que SGBDs relacionais consigam garantir consistência para os dados eles usam o conceito de transações, o que requer um bloqueio nos dados durante um certo período de tempo. Dessa forma, quando o banco recebe várias requisições simultâneas em um mesmo dado os usuários são obrigados à esperarem em uma fila [22].

A necessidade de transformar os dados em tabelas causa um aumento na complexidade da operação pois requer o uso de complexos algoritmos de mapeamento e estrutura. Mesmo quando uma base de dados pode ser coberta pelo modelo relacional, as vezes as diversas garantias providas por esse modelo gera uma sobrecarga que não seria necessária para tarefas simples. O schema rigoroso pode ser pesado para aplicações que precisam de velocidade, como aplicações web e blogs que possuem diversos tipos de atributos. Textos, comentários, imagens, vídeos fonte, código e outras informações precisam ser armazenadas em diversas tabelas, e como as aplicações na web são muito ágeis, precisam ser amparadas por uma base de dados igualmente ágil e com um schema de fácil adaptação [21].

O considerável aumento na quantidade de dados deve ser considerado por grandes empresas como Facebook, Amazon e Google. Além de tratar terabytes/petabytes de dados, realizar requisições de leitura e escrita na base a todo o momento essas empresas devem se preocupar com o tempo que essas transações estão levando, ou seja, a latência. Para tratar esses requisitos é preciso manter milhares de máquinas com um hardware moderno e veloz. Por ter que cumprir com os requisitos de ACID e manter os dados normalizados, um modelo relacional não é adequado para esse cenário, visto que as operações de join bloqueiam os dados e influenciam negativamente no desempenho da aplicação.

Outro requisito fundamental para as grandes empresas é a disponibilidade de seus serviços. Para isso a base de dados deve ser facilmente replicável e fornecer uma forma automática de tratamento à falha de bases ou do datacenter. Esses SGBDs também devem ser capazes de balancear a carga em várias máquinas para não sobrecarregar um único servidor. Bancos relacionais priorizam a consistência em detrimento à disponibilidade e também possuem um mecanismo de replicação limitado.

Esses problemas podem ser resolvidos de algumas formas. Primeiramente optamos por um upgrade simples de hardware. Se o problema persistir a próxima opção seria adicionarmos novos servidores ao cluster, porém com os problemas de consistência e replicação durante o uso regular e em cenários de falha. A próxima etapa seria melhorar a configuração do gerenciador de banco de dados. Caso as opções de melhoria no SGBD se esgotem é preciso melhorar a aplicação. Verifica-se o desempenho das consultas, criamos índices e etc. Se o desempenho ainda não for satisfatório então talvez coloquemos uma camada de cache, mas que também gera um problema de consistência. Se mesmo assim o desempenho não atender as expectativas, então é necessário pensarmos novamente no SGBD. A última opção seria uma desnормarização do banco, mas assim se estaria indo contra os princípios da modelagem relacional e das regras normais [22].

Dado toda essa problemática surge uma opção. Bancos de dados que não seguem o paradigma relacional. Os dados não são normalizados.

2.2.2 Bases Não Relacionais

O NoSQL foi proposto em 2009 e quebrou os limites das bases de dados relacionais e das propriedades ACID. Os banco de dados NoSQL geralmente não proveem as propriedades ACID: atualizações são eventualmente propagadas, mas há garantias limitadas para a consistência de leituras. Alguns autores sugeriram o acrônimo ‘BASE’ em contraste ao ‘ACID’ [15]. O teorema CAP, o teorema BASE e o conceito de consistência eventual são os fundamentos do NoSQL. Abaixo vamos apresentá-los.

Teorema CAP

O teorema CAP (Figura 2.2) foi proposto por Eric Brewer. CAP significa Consistência, disponibilidade e tolerância a particionamento de rede. A idéia principal desse teorema é que os sistemas distribuídos não podem atender, ao mesmo tempo, essas três características. Podem atender somente duas delas [32].




Figura 2.2: Teorema CAP [18]

Nesse caso a disponibilidade permite que os clientes sempre poderão executar leituras e escritas em um período de tempo. Um banco de dados distribuído que permite particionamento é tolerante a falhas de conexão e permite a distribuição em nós separados [27].

Um sistema que permite o particionamento só poderá prover uma consistência forte se sacrificar a disponibilidade. Isso porque cada operação de escrita somente será concluída se os dados forem replicados para todos os nós, o que nem sempre é possível em um ambiente com falhas de conexão ou outras falhas de hardware [27].

Sendo assim, temos três arquiteturas possíveis: CA, AP e CP. Como atualmente a grande maioria dos sistemas é implantada na web, a disponibilidade é indispensável.

Isso nos permite utilizar somente com as arquiteturas CA e AP. Para sistemas web, a disponibilidade e a tolerância ao particionamento são mais importantes que a consistência. Já é suficiente quando um sistema web possui consistência eventual [32].

Teorema BASE

O teorema BASE é um produto do teorema CAP. As propriedades BASE são completamente diferentes das ACID. BASE é um acrônimo para: Basically Available (Basicamente Disponível), Soft-state (base otimizada pelo uso) e Eventual consistency (Disponibilidade Eventual) [32].

- Basically Available : Significa que eventuais falhas de particionamento são suportadas.
- Soft-state: Significa que em um período de tempo o estado do sistema pode ser assíncrono.
- Eventual consistency: O sistema ‘deve’ ser consistente.

Consistência Eventual

Por causa o teorema CAP, a maioria dos banco de dados NoSQL proveem consistência eventual. Abaixo estão as definições de consistência forte e consistência eventual.

Consistência forte: Significa que todos os processos conectados em um banco de dados sempre verão a mesma versão de um valor e uma nova atualização é instantaneamente refletida por qualquer operação de leitura até outra mudança ser feita por outra operação de escrita [27]. Na figura 2.3 temos um exemplo gráfico.




Figura 2.3: Consistência Forte: O processo A, B e C sempre estão vendo a mesma versão do banco de dados [27].

Consistência Eventual: É um tipo de consistência fraca. O não garante que todos os processos veem a mesma versão dos dados. Isso pode ocorrer por causa das janelas de inconsistência e é geralmente causada pela replicação dos dados nos diferentes nós [27]. Na figura 2.4 temos um exemplo gráfico.

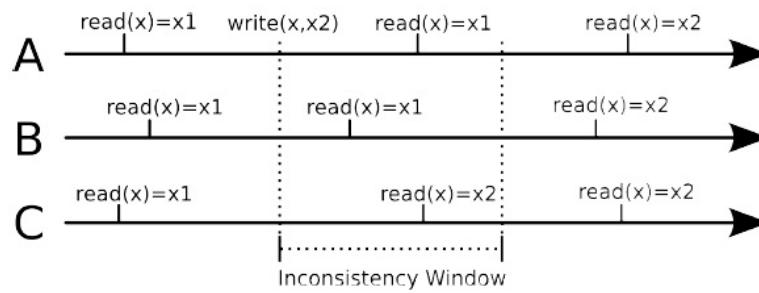


Figura 2.4: Consistência Eventual: Os processos A, B e C podem visualizar diferentes versões dos dados durante a janela de inconsistência causada pela replicação assíncrona [27].

Capítulo 3

NoSql

Nesse capítulo iniciaremos com a definição de o que é o termo NoSQL e, após vermos como essa nova forma de se pensar em banco de dados surgiu, conheceremos os principais tipos de banco de dados não relacionais e como eles armazenam os seus dados.

3.1 Definição de NoSQL

O termo NoSql é a junção de duas palavras. No and SQL. Ao pé da letra significa que é uma tecnologia/produto que trabalha de forma contrária à tecnologia dos banco relacionais (adeptos do SQL). O termo é usado com o sentido de Não Relacional. Atualmente o termo NoSql é traduzido para "Not only Sql", ou seja "Não só Sql". Saindo da definição, NoSql é um termo genérico para uma classe definida de banco de dados não-relacionais que armazenam os dados de forma diferente da conhecida modelagem relacional e que surgiram com o propósito de sanar algumas dificuldades encontradas com o modelo relacional. NoSql não é um produto, mas a uma classe de produtos e conceitos de armazenagem e manipulação de dados.

O que diferencia os bancos de dados NoSql dos relacionais são os seus modelos de dados sem um schema definido. Os bancos de dados NoSql podem ser classificados, segundo seu modelo de dados, em quatro grupos: chave-valor, orientados a documentos, orientados a colunas e baseados em grafos [14, 21].

3.2 História

Bancos de dados que usam a modelagem não relacionais não são novidades. Conforme discutido no livro (NoSql Professional) eles surgiram junto com as primeiras máquinas de computar. Bases não relacionais ficaram conhecidas e cresceram por causa do uso de mainframes e em domínios específicos como o armazenamento de credenciais para autenticação. Esse NoSql que conhecemos hoje é uma nova visão, ou como diz fulano em (NoSql Professional), uma reencarnação que nasceu no mundo de aplicações web que necessitam de recursos escaláveis para tratar de sua enorme massa de dados. Apesar de o paradigma NoSql já ter sido criado há algum tempo nenhum ele só tomou as proporções atuais depois que grandes empresas como Google, Amazon e Facebook começam a usar em suas arquiteturas [21].

Ao utilizar SGBD's relacionais com grandes quantidade de dados surgem problemas como falta de eficiência no processamento, uma paralelização não efetiva, alto custo e escalabilidade limitada. Sendo um gigante da internet, o Google, se não for a empresa que manipula a maior quantidade de dados, é com certeza uma das maiores e ao se deparar com essa problemática construiu a sua própria infraestrutura para que o seu mecanismo de busca e outras aplicações pudessem tratar a massa de dados de forma eficiente.

Com o lançamento de artigos pelo Google que explicavam em partes como o problema foi solucionado, desenvolvedores de software livre criaram o primeiro motor de busca de código aberto que replicava algumas característica da infraestrutura do Google, o Lucene. Logo depois, os principais desenvolvedores do Lucene se juntaram ao Yahoo e com a ajuda de diversos outros desenvolvedores criaram uma estrutura que imitada todas as peças da infraestrutura de computação distribuída do Google. Essa solução livre é o Hadoop. Nessa mesma época surgiu a idéia do NoSql.

O sucesso do Google e o Hadoop ajudaram a impulsionar novos conceitos de computação distribuída, NoSql e o próprio projeto Hadoop. Um ano após o lançamento dos artigos do Google outra gigante da internet resolveu compartilhar o seu caso de sucesso. Em 2007 a Amazon mostrou ao mundo sua solução de base de dados distribuída, disponível e consistente que se chama Dynamo.

Após Google e Amazon mostrarem para o mundo que o NoSql dava certo começaram a surgim diversos outros produtos nessa linha. O NoSql e os conceitos de manipulação de Big Data ganharam espaço e forma surgindo diversos casos de uso de sucesso de grandes companhias como o Facebook, Netflix, Yahoo, EBay, Hulu, IBM e diversas outras.

3.3 Os Principais Tipos de Banco de Dados NoSql

3.3.1 Chave-Valor

Bancos de dados NoSql que usam a modelagem Chave-Valor armazenam os dados indexados por um valor chave. A base é similar a um dicionário, onde os dados são endereçados por uma única chave. Uma vez que os dados são armazenados, é através das suas chaves a única forma de recuperá-los. Os valores são isolados e independentes um dos outros, sendo necessário tratar isso na aplicação. Por isso banco chave-valor são livres de schema. Isso permite que novos tipos de dados sejam inseridos em tempo de execução sem que o banco entre em conflito e sem influenciar na disponibilidade do sistema [21, 24].

Alguns exemplos de banco de dados que usam esse tipo de modelagem são: RIAK, LevelDB, Voldemort, redis [7].

3.3.2 Orientados a Documentos

A modelagem orientada a documentos armazena os dados encapsulados em pares de chave-valor em JSON ou em outro padrão semelhante. Dentro dos documentos as chaves devem ser únicas. Cada documento recebe um identificador que também é único dentro de uma coleção de documentos. Os documentos são as unidades básicas e não têm uma estrutura definida como nas tabelas do modelo relacional, ou seja, não tem um schema de dados definido. Ao armazenar os dados em JSON há uma vantagem adicional que é o

suporte a tipos de dados, o que torna a forma de armazenamento mais amigável para os desenvolvedores [14, 21].

Os exemplos mais significativos são: CouchDB, MongoDB e Riak [21].

Listing 3.1: Exemplo de arquivo do CouchDB

```
{
  "Subject": "I like Plankton",
  "Author": "Rusty",
  "PostedDate": "5/23/2006",
  "Tags": ["plankton", "baseball", "decisions"],
  "Body": "I decided today that I don't like baseball. I like plankton."
}
```

3.3.3 Orientados a Colunas

Nesse tipo de modelagem o paradigma passa a ser de orientação a atributos(colunas).Ao contrário da modelagem chave-valor, agora os dados são armazenados usando tabelas sem um schema definido, mas sem suporte a associação entre elas . Figura 3.1 Segundo Jing Han et all, um banco orientado a colunas tem as seguintes características [20]:

1. Os dados são armazenados em colunas
2. Cada coluna de dado é um índice do banco
3. Acessar somente colunas faz com que haja redução de I/O nos resultados das consultas
4. Consultas simultâneas, isto é, cada coluna é tratada por um processo
5. Possuem o mesmo tipo de dados, características semelhantes e boa taxa de compressão

Em geral esse tipo de banco é mais vantajoso para aplicações de agregação e data warehouses. Alguns exemplos são: Cassandra e Hypertable [7].

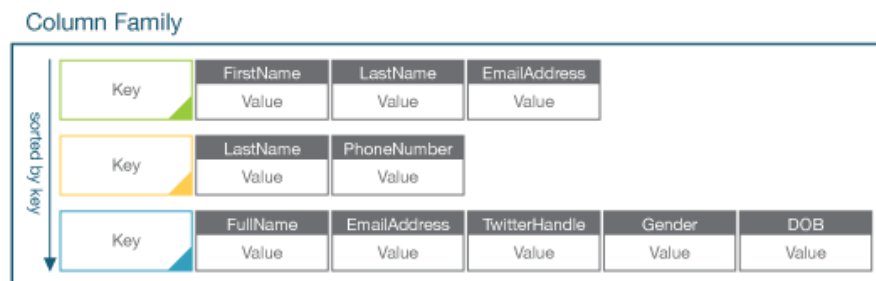


Figura 3.1: Modelagem orientada a colunas

Tabela 3.1: BSON - Tipos Suportados

Tipo	Número
Double	1
String	2
Object	3
Array	4
Binary Data	5
Object id	7
Boolean	8
Date	9
Null	10
Regular Expression	11
JavaScript	13
Symbol	14
JavaScript (with scope)	15
32-bit integer	16
Timestamp	17
64-bit integer	18
Min key	255
Max key	127

3.3.4 Baseados em Grafos

Nessa categoria os dados são armazenados em nós de um grafo cujas arestas representam o tipo de associação entre esses nós. Esse tipo de banco é especializado em manter dados fortemente ligados. O twitter armazenar as relações entre os seus usuários no seu próprio banco de dados baseados em grafos, o FlockDB, que é otimizado para listas de relações muito grandes, leituras e escritas [21]. Alguns exemplos são: Neo4J, infoGrid e FlockDB [7].

3.4 MongoDB

Essa seção foi baseada no site oficial do MongoDB [5] exceto quando explicitamente citado.

MongoDB é um banco de dados NoSQL, de código aberto, orientado a documentos, schema-free e escrito em C++. Os dados são persistidos em coleções de dados que são representados usando o BSON, um formato binário similar ao JSON (Figura 3.2). O MongoDB tem suporte a todos os tipos de dados JSON como string, inteiro, booleano, double, array e objeto. Por usar codificação BSON o MongoDB suporta alguns tipos de dados adicionais como data, binary data, regular expression e code [31]. Na Figura 2.1 podemos ver os tipos suportados pelo BSON.

Como não usa o mesmo formato de armazenamento dos SGBDS relacionais, o MongoDB armazena os seus dados em coleções, que são equivalentes às tabelas. Uma Coleção

pode ter um ou mais documentos; são equivalentes as linhas em uma tabela de um banco de dados relacional. Cada documento tem um ou mais campos, o que corresponde a uma coluna.

Diferente do que a maioria das pessoas estão acostumadas, o MongoDB não trabalha com uma estrutura de dados bem definida (schema), ou melhor dizendo, ele usa schemas dinâmicos. Com ele é possível criar coleções sem que a estrutura, campos ou tipos de valores dos documentos estejam definidos. Essa forma flexível de armazenar os dados nos permite trabalhar com estruturas e dados bastante heterogêneos.

```
var mydoc = {
  _id: ObjectId("5099803df3f4948bd2f98391"),
  name: { first: "Alan", last: "Turing" },
  birth: new Date('Jun 23, 1912'),
  death: new Date('Jun 07, 1954'),
  contribs: [ "Turing machine", "Turing test", "Turingery" ],
  views : NumberLong(1250000)
}
```

Figura 3.2: Documento BSON usado no MongoDB [5]

Quanto mais controle, mais custosa é uma operação para o sistema gerenciador de banco de dados. Os banco de dados NoSQL, como dito anteriormente, foram criados para suprir algumas características que os banco de dados relacionais não atendiam. Uma dessas características é a velocidade com que operações de consulta, escrita, atualização e exclusão são executadas. Para que a velocidade dessas transações fosse aumentada, foi preciso retirar alguns controles e, com isso, os banco de dados NoSQL não se comprometem com todas as características ACID.

O MongoDB não provê transações ACID, mas possui alguns recursos transacionais básicos. Operações atômicas são possíveis no escopo de um único documento. Na tabela abaixo temos alguns exemplos de operações em SQL e suas correspondentes no MongoDB.

3.4.1 Modelagem dos Dados

Cada documento tem um campo chamado ID que é utilizado como chave primária. Para aumentar a velocidade das queries é possível habilitar índices para os campos que são utilizados nas consultas. O MongoDB também suporta índices em sub-documentos e em arrays.

Ao contrário dos bancos de dados convencionais o MongoDB possui um schema flexível e não nos força a determinar uma estrutura antes de inserir os dados. As coleções no MongoDB não nos impedem de evoluir a estrutura dos documentos [27].

Para representar as relações entre os objetos temos duas estratégias: referências e sub-documentos [27].

Referências

Essa estratégia representa as relações entre os dados incluindo links ou referências de um documento para outro. Para acessar os dados referenciados a aplicação deve resolver a referência. Na figura 3.3, temos um exemplo de modelagem utilizando referência.

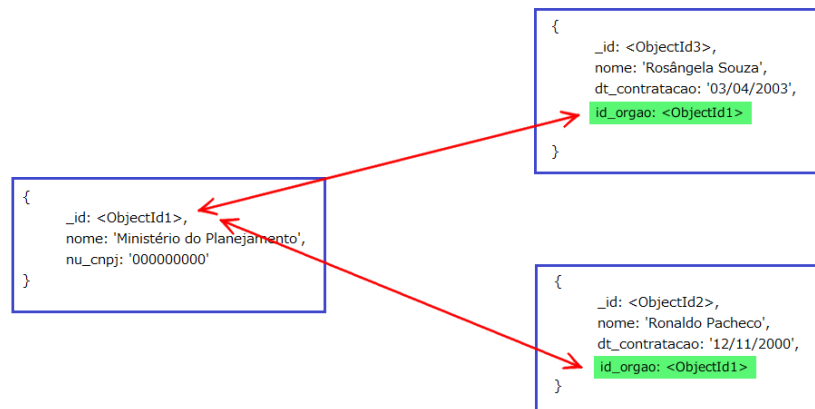


Figura 3.3: Modelagem utilizando referência. Adaptado de [5]

Seguem algumas ocasiões em que podemos utilizar essa estratégia de modelagem:

- Quando, ao criar sub-documentos, criamos duplicação de dados e essa duplicação não nos dá um ganho de performance vantajoso.
- Quando desejamos representar complexas relações de n para n.
- Para representar grandes um grande volume de dados de forma hierárquica.

Ao implementar as referências temos mais flexibilidade se compararmos com os sub-documentos. Em contrapartida, ao realizarmos consultas, essas referências deverão ser traduzidas, o que gera mais consultas ao servidor [27].

Sub-Documentos

A outra estratégia possível é o uso de sub-documentos. Ao utilizar essa forma de armazenamento os dados relacionados são armazenados em um único documento. O MongoDB permite armazenar essas relações em sub-documentos ou arrays de documentos. Veja um exemplo desse tipo de modelagem na figura 3.4.

Seguem algumas ocasiões em que podemos utilizar os sub-documentos:

- Em relações um para um;
- Em relações um para muitos. Nesses relacionamentos o objeto que se repete deve estar contido no outro objeto;

Os sub-documentos aumentam a performance de operações de leitura e nos dá a vantagem de obter os dados necessários em uma simples consulta ao banco. Com os sub-documentos também é possível realizar atualizações de forma atômica [27].

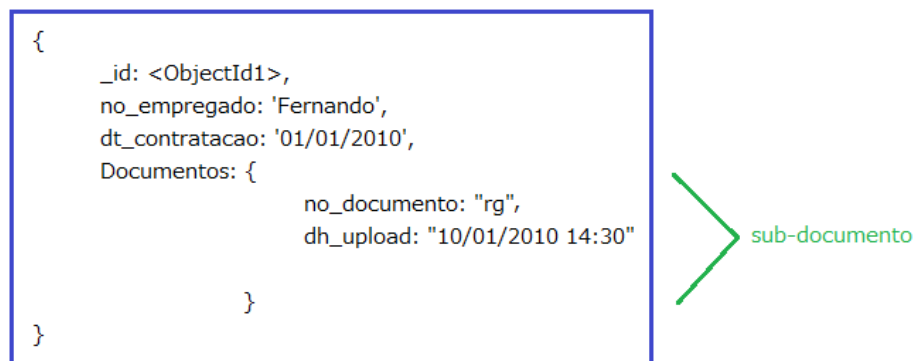


Figura 3.4: Modelagem utilizando sub-documento. Adaptado de [5]

3.4.2 Linguagem de Consulta

A sintaxe da linguagem de consulta do MongoDB é similar ao JSON. A linguagem de consulta permite consultar todos os documentos em uma coleção, inclusive os sub-documentos e os arrays [27].

A linguagem de consulta suporta [27]:

- Consultas em documentos e sub-documentos
- Comparações
- Operações lógicas
- Ordenação por múltiplos campos
- Group by
- Uma agregação por consulta

Adicionalmente o MongoDB permite realizar consultas com agregações mais complexas utilizando uma variação do MapReduce [27].

Nas tabelas 3.2 e 3.3 temos algumas comparações entre a linguagem utilizada pelo MongoDB e o SQL.

3.4.3 Replicação

Replicação é o processo de sincronizar dados através de diferentes servidores. Com a replicação é possível prover redundância e aumentar a disponibilidade dos dados, além de proteger os dados de uma possível falha de hardware ou catástrofes.

Um conjunto de réplicas é um grupo de instâncias do MongoDB com os mesmos dados. Na arquitetura de um conjunto de replicação somente um servidor, o primário, recebe todas as requisições de escrita. Os outros servidores somente replicam as operações em suas instâncias. A figura 3.5 representa a arquitetura para replicação.

Como somente um nó recebe todas as operações de escrita, para suportar a replicação, o nó primário armazena em log todas as operações. Os nós secundários replicam os logs do nó primário e, em seguida, realizam as operações em suas instâncias. Caso o nó primário fique indisponível, o conjunto de replicação eleje um novo nó para ser o primário. Por padrão, as requisições de leitura são feitas ao nó primário, porém isso pode ser alterado. Como a replicação é assíncrona, se as preferências de leitura forem alteradas os dados retornados podem não ser os mais atuais.

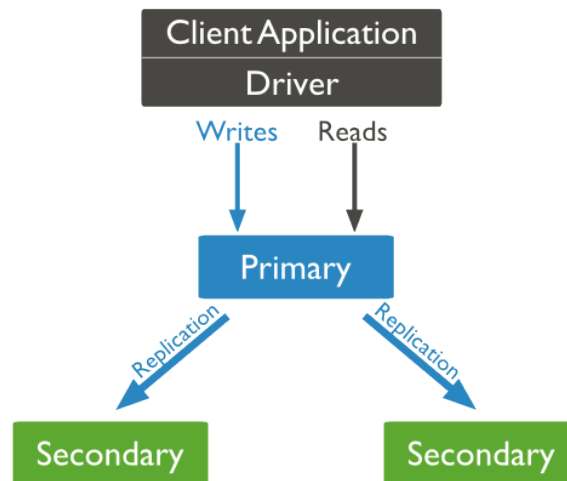


Figura 3.5: Arquitetura de Replicação [5]

3.4.4 Decomposição (Sharding)

Sharding, ou decomposição, é quando separamos a localização física dos dados, despedaçando cada informação e colocando-as em nós diferentes. Essa técnica é utilizada para trabalhar com dados de grande volume e com alta vazão de operações. A decomposição é a alternativa à escalabilidade vertical. No MongoDB a decomposição é implementada com o uso de um cluster de decomposição. Os componentes desse cluster são: Shards, roteadores de consulta e servidores de configuração (Figura 3.6).

Os shards armazenam os dados.

Os roteadores de consulta, ou mongos, se comunicam com os clientes e direcionam as operações ao shard ou shards apropriados.

Os servidores de configuração armazenam os metadados do cluster. Ele contém o mapa do cluster. O roteador de consulta utiliza esse componente para encontrar os shards que serão utilizados.

3.4.5 Tratamento de Falhas

O MongoDB não utiliza log de transações para garantir a durabilidade dos dados. E por utilizar arquivos mapeados em memória, implementa escrita preguiçosa (lazy write). Sendo assim, se um nó MongoDB falhar, provavelmente algum dado será perdido [27].




Figura 3.6: Cluster de Sharding [5]

Tabela 3.2: Declarações SQL vs Declarações MongoDB. Adaptado de [5]

SQL	MongoDB
<pre>CREATE TABLE users (id MEDIUMINT NOT NULL AUTO_INCREMENT, user_id Varchar(30), age Number, status char(1), PRIMARY KEY (id))</pre>	<p>O documento é criado na primeira operação de inserção. Se o campo id não for especificado ele é automaticamente gerado.</p> <pre>db.users.insert({ user_id: "abc123", age: 55, status: "A" })</pre>
<pre>ALTER TABLE users ADD join_date DATETIME</pre>	<p>O MongoDB não amarra a estrutura das coleções. Não existe alteração estrutural no nível das coleções. As alterações ocorrem no nível dos documentos.</p> <pre>db.users.update({ }, { \$set: { join_date: new Date() } }, { multi: true })</pre>
<pre>ALTER TABLE users DROP COLUMN join_date</pre>	<pre>db.users.update({ }, { \$unset: { join_date: "" } }, { multi: true })</pre>
<pre>DROP TABLE users</pre>	<pre>db.users.drop()</pre>

Tabela 3.3: SQL Select vs MongoDB Select. Adaptado de [5]

SQL	MongoDB
SELECT * FROM users	db.users.find()
SELECT id, user_id, status FROM users	db.users.find({ }, { user_id: 1, status: 1 })
SELECT * FROM users WHERE status = "A"	db.users.find({ status: "A" })
SELECT * FROM users WHERE status = "A" AND age = 50	db.users.find({ status: "A", age: 50 })
SELECT COUNT (*) FROM users	db.users.count() ou db.users.find().count()
EXPLAIN SELECT * FROM users WHERE status = "A"	db.users.find({ status: "A" }).explain()

Capítulo 4

Testes

Nesse capítulo veremos como o teste está diretamente ligado à qualidade de software, os principais tipos de testes, conceitos e ferramentas de automação, veremos quais os tipos de testes que serão aplicados ao nosso projeto e a importância da infra-estrutura de testes em um projeto.

4.1 Definição

Segundo o dicionário de termos da IEEE, teste é definido da seguinte forma:

- Teste: atividades nas quais um sistema ou um componente é executado sob determinadas condições e os resultados são observados ou gravados, e uma avaliação é feita observando determinado comportamento do sistema ou do componente;

4.2 Teste de Software e Qualidade de Software

O teste de software está diretamente ligado com a qualidade do software que está sendo desenvolvido. Podemos ver essa ligação já na definição de qualidade de software.

- Qualidade de Software: Conformidade a requisitos funcionais e de desenvolvimento explicitamente declarados, a padrões de desenvolvimento claramente documentados e a características implícitas que são esperadas de todo software profissionalmente desenvolvido.

Dentro da qualidade de software temos a atividade de garantia de qualidade de software e esta compreende uma variedade de tarefas associadas a sete grandes atividades, entre elas a atividade de testes:

1. Aplicação de métodos técnicos;
2. realização de revisões técnicas formais;
3. Atividades de testes de software;
4. Aplicação de padrões;

Tabela 4.1: Tipos de teste e sua característica de qualidade correspondente

Tipos de Teste	Características de qualidade
Funcionalidade	Funcionalidade
Interfaces	Conectividade
Carga	Continuidade, Performance
Produção	Operabilidade
Recuperação	Recuperação
Regressão id	Todas
Segurança	Segurança

5. Controle de mudanças;
6. Medição;
7. Manutenção de registros e reportagem;

Então podemos estar certos de que se queremos um software que atenda aos requisitos especificados, funcionais e não funcionais, que possua uma quantidade de erros reduzida e um desempenho que atenda ao usuário, uma tarefa que não pode ser dispensada é o teste da aplicação. Como já dito anteriormente, teste de software e qualidade de software estão intimamente ligados, na tabela 4.1 podemos ver quais as características de qualidade são verificadas por determinados tipos de testes.

4.3 Tipos de Testes

O teste de software nos permite trabalhar com diversas estratégias e em diferentes níveis da aplicação. Emerson Rios e Trayahú Moreira [28] dizem que muitas vezes os tipos de software se sobrepõem, sendo até mesmo as suas definições abrangentes ou específicas, conforme sua execução. Nessa seção listaremos os principais tipos de testes descritos por esses autores.

4.3.1 Aplicados a cada estágio de teste

Testes Caixa Preta

Esse tipo de teste tem como objetivo verificar as funcionalidades da aplicação e a aderência aos requisitos, do ponto de vista do usuário, sem se basear no código ou lógica interna da aplicação.

Testes Caixa Branca

Os testes de caixa branca avaliam o código, a lógica interna do componente, as configurações e outros elementos técnicos.

4.3.2 Estágios (ou Níveis) de teste

Testes unitários

Esse é o tipo de teste que analisa o estágio mais baixo da aplicação. São aplicados nos menores componentes de código criados, verificando o atendimento as especificações e funcionalidades. Verificam o funcionamento de um pedaço do sistema, componente ou programa, isoladamente. Geralmente são realizados pelos próprios desenvolvedores.

Testes de integração

Esse teste visa testar se as interações entre os componentes da aplicação está resultando em algum tipo de erro. Tem como objetivo assegurar que as interfaces funcionem corretamente e que os dados são processados corretamente. Componentes podem ser pedaços de código, módulos, aplicações distintas, clientes e servidores etc. Esse tipo de teste possui várias estratégias. Podemos testar a integração desde os componentes de mais baixo nível (Bottom-up) até o sistema como um todo (Teste de sistema). Para o nosso trabalho nos atentaremos ao teste de sistema.

Testes de sistema

Esse teste é executado sobre o sistema como um todo, ou um subsistema, dentro de um ambiente operacional controlado. Deve ser simulada a operação normal do sistema, sendo testadas todas as suas funções de forma mais próxima possível do que irá ocorrer no ambiente de produção. É nesse estágio que deve-se realizar os testes de carga, performance, usabilidade, compatibilidade, segurança e recuperação.

Testes de aceitação

São realizados pelos usuários e visam garantir que a solução atenda aos objetivos do negócio e a seus requisitos, verificando as funcionalidades e a usabilidade do software.

4.3.3 Outros tipos de testes

Testes Back-to-back

É quando o mesmo teste é executado em versões diferentes do software e os resultados são comparados.

Testes de Configuração

É nesse tipo de teste de a execução da aplicação é analisada em diferentes configurações de ambiente.

Testes de Usabilidade

Mede a facilidade de uso da aplicação pelos usuários. É mais comum em aplicações web.

Testes de Segurança

Verifica o quão segura é a aplicação a acesso de usuários não autorizados.

Testes de Recuperação

Mede a qualidade da recuperação do software após falhas de hardware ou outro problemas inesperados.

Testes de Compatibilidade

Verifica se um software é capaz de ser executado em um ambiente determinado.

Testes de Desempenho

Verifica a adequação da aplicação aos níveis de desempenho e tempo de resposta definidos nos requisitos. Também são conhecidos como testes de performance.

4.4 Testes de Carga e de Performance

Como o objetivo do trabalho é medir o desempenho da nossa aplicação com o uso de diferentes bancos de dados, restringimos os testes que serão usados no nosso projeto aos testes de carga e performance.

4.4.1 Testes de carga

Permite avaliar a aplicação sob uma alta carga de dados, repetidas entradas de dados, consultas complexas ou uma grande quantidade simultânea de usuários. Dessa forma é possível medir o nível de escalabilidade da aplicação. Esse tipo de teste deve ser aplicado durante os testes de sistema e também podem ser chamados de testes de estresse.

4.4.2 Teste de Performance

Molyneaux fala que do ponto de vista dos usuários, uma aplicação possui boa performance quando ela o permite realizar determinada tarefa sem demora [26]. Ela ainda diz que em uma aplicação performática o usuário nunca poderá se deparar com uma tela vazia ao realizar operações. O teste de performance é usado para medir o desempenho, em tempo de execução, e com todos os módulos integrados. Conforme Molyneaux, dividiremos os requisitos de performance em dois: orientados a serviço e orientados a eficiência.

Os indicadores de performance orientados a serviço são a disponibilidade e o tempo de resposta. Eles medem a qualidade do serviço que a aplicação está provendo ao usuário. Já os indicadores orientados a eficiência são a vazão e utilização. Vamos definir esses termos:

- Disponibilidade: É a característica de estar disponível para o usuário. Em softwares críticos, qualquer período de indisponibilidade pode gerar grandes prejuízos.
- Tempo de resposta: É o intervalo de tempo entre a requisição e a resposta da aplicação.

- Vazão: É a taxa em que os eventos da aplicação ocorrem.
- Utilização: É a porcentagem da capacidade total de recursos da aplicação que esta sendo usada.

Para que o nosso processo de teste de performance seja bem sucedido precisamos seguir algumas etapas.

1. Escolher uma ferramenta de teste de performance apropriada;
2. Desenvolver um ambiente de teste adequado a realidade dos testes e o mais próximo da realidade;
3. Escolher os objetivos que desejamos alcançar no trabalho;
4. Identificar e criar scripts para as transações críticas para o negócio;

4.5 Automação de Testes

Durante muito tempo os testes de software foram feitos manualmente. Os proprios programadores eram encarregados de simular as mais diversas situações [28]. Com o passar do tempo as aplicações se tornaram muito mais complexas e, conseqüentemente, o processo de teste manual se tornou inviável. Esse cenário foi ideal para que surgissem ferramentas de automação do processo de testes.

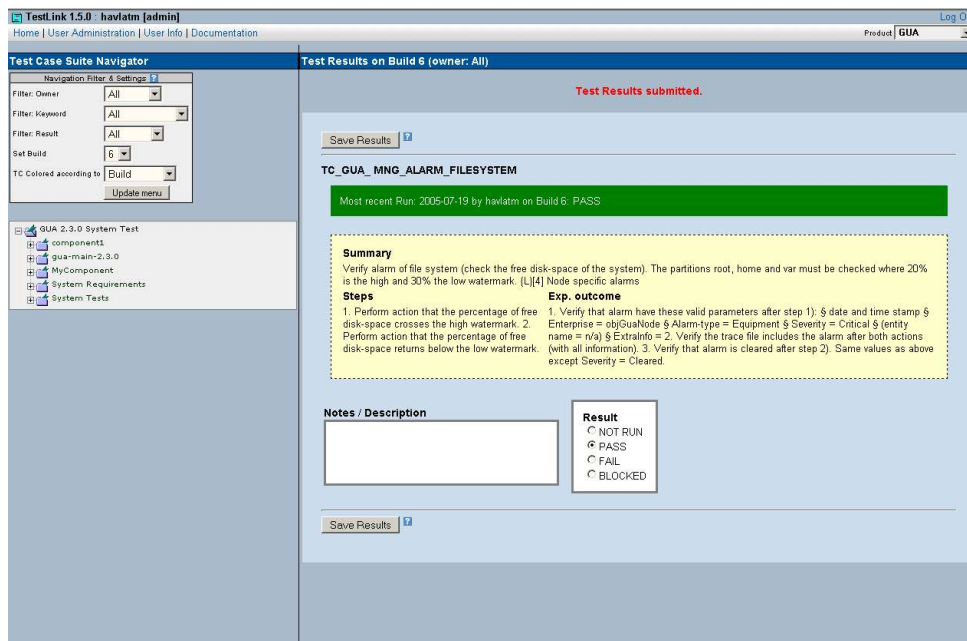


Figura 4.1: TestLink - acompanhamento/suporte [10]

As ferramentas de automação de teste visam facilitar o processo de teste e podem auxiliar no desenvolvimento dos testes, execução, manuseio das informações de resultado e a comunicação entre os envolvidos no processo. Utilizando scripts essas ferramentas

são capazes de simular a utilização da aplicação por um ou vários usuários e, além disso, podem ser simulados vários cenários de uso. As ferramentas de teste podem ser divididas em três grupos: desenvolvimento, execução 4.2 e acompanhamento/suporte 4.1.

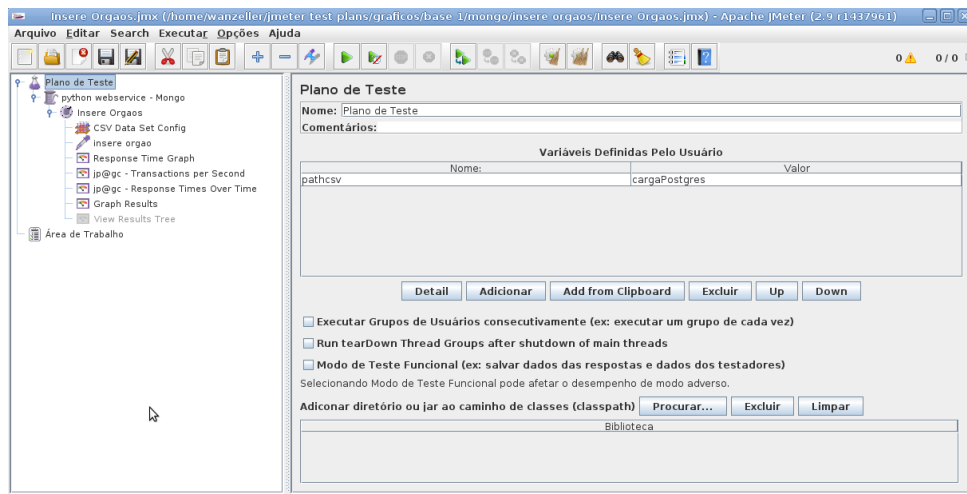


Figura 4.2: JMeter - Ferramenta para execução de testes [1]

4.6 JMeter

O Apache JMeter é uma aplicação open source, 100% desenvolvida em java e que foi criada para a execução de testes de carga e para medição de performance. Foi originalmente criado para testar aplicações web. O JMeter pode ser usado para testar a performance tanto de recursos estáticos quanto de recursos dinâmicos (arquivos, servlets, scripts Perl, objetos Java, Bancos de dados e queries, Servidores FTP e etc). Com ele é possível simular cargas pesadas em um servidor, rede ou objeto para testar o seu comportamento ou para analisar a performance em diferentes tipos de carga [1].

O JMeter pode testar diferentes tipos de servidores como:

- Web - HTTP, HTTPS
- SOAP
- Database via JDBC
- LDAP
- JMS
- Mail - SMTP, POP3 e IMAP
- Comandos nativos ou scripts shell

Para realizarmos testes no JMeter precisamos criar um plano de teste. O plano de teste descreve uma série de passos que o JMeter terá de executar. O plano de teste pode conter os seguintes elementos: Grupo de Thread, controladores lógicos, testadores,

ouvintes, timers, assertions e elementos de configuração. A seguir vamos ver os elementos que serão usados nos planos de teste desse trabalho.

4.6.1 Testador

Quando iniciamos o nosso plano de teste, o primeiro item que devemos procurar é o testador. Os testadores basicamente enviam requisições aos servidores e aguardam retorno. Cada testador possui diversas configurações que podem ser customizadas.

Requisição SOAP/XML - RPC

O testador SOAP (figura 4.3) é usado para mandar requisições SOAP para um Web service. Ele cria uma requisição HTTP POST com os dados especificados e executa o POST. As principais configurações são:

- **URL:** Endereço do WSDL do Web service.
- **Ação SOAP:** Endereço da requisição SOAP que o testador utilizará.
- **Dados SOAP/XML-RPC:** Requisição que será enviada para o Web service. Deve estar em formato XML.




Figura 4.3: Testador de Requisição SOAP/XML - RPC

4.6.2 Ouvintes

Os ouvintes nos permite ter acesso às informações geradas pelo JMeter durante os testes. Temos ouvintes que geram gráficos, gravam informações em arquivos, listam as respostas e outros vários.

Gráfico de Resultados

O gráfico de resultados gera um gráfico com os tempos de todas as requisições. Na legenda do gráfico temos o tempo da requisição atual (preto), a média atual de todas as requisições (azul), a derivação atual (vermelho), e a vazão atual (verde), todas em milissegundos. A vazão representa o número de transações por minuto (os atrasos causados pelo processamento interno do JMeter não são considerados).

Gráfico de Tempo de Resposta

O gráfico de tempo de resposta plota uma linha no gráfico que descreve a evolução do tempo de resposta de cada requisição durante o teste.

4.6.3 Elemento de Configuração

Os elementos de configuração podem ser utilizados para configurar padrões e variáveis que serão utilizadas pelos testadores.

Configuração de Dados CSV

Esse elemento de configuração é usado para ler linhas de um arquivo e armazená-las em variáveis. Podemos ver um exemplo na figura 4.4. Para realizar os testes de inserção de dados no banco esse elemento será de grande importância.

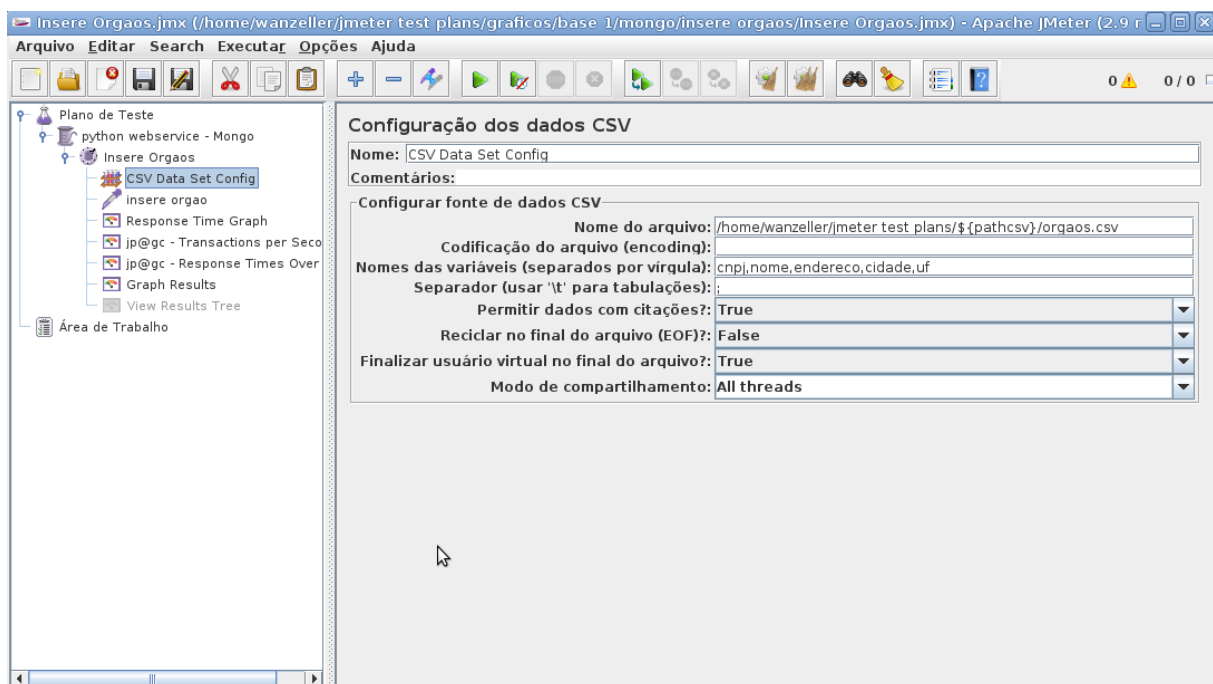


Figura 4.4: Elemento de Configuração de Dados CSV

Capítulo 5

Web-Service

Nesse capítulo daremos uma visão de o que é web service, e mostraremos um pouco sobre os seus principais componentes. Esse capítulo foi baseado no w3c schools [6] exeto quando citado explicitamente.

5.1 O que é web-service?

Web service são componentes que podem ser acessados via protocolo http. Atualmente é muito usado na comunicação entre aplicações diferentes. O acesso a um webservice é via http, mas internamente existe dados formatados em xml que estão empacotados no protocolo SOAP (Simple Object Access Protocol).

Hoje várias aplicações podem acessar a web usando os browsers e nem sempre essas aplicações conversam entre si. Para que a comunicação entre essas diversar aplicações se tornasse possível, independente da plataforma em que estivessem desenvolvidas, foi criado o conceito de web service. Usando web services, as aplicações podem publicar suas funções para toda a web. Usando o XML para codificar e SOAP para transportar os dados, os web services elevaram as aplicações web para outro nível.

5.2 Componentes de um Web-Service

Um web service é formado por três elementos: SOAP, WSDL e UDDI.

5.2.1 SOAP

O SOAP (Simple Object Access Protoco) é um protocolo leve para troca de informações que foi criado pela Microsoft, Ariba e IBM para padronizar a transferência de dados em diversas aplicações, por isso, se dá em XML. Parte da sua especificação é composta por um conjunto de regras de como utilizar o XML para representar os dados. Outra parte define o formato de mensagens, convenções para representar as chamadas de procedimento remoto (RPCs) utilizando o SOAP, e associações ao protocolo HTTP.

SOAP é:

- Um protocolo de comunicação;

- É usado para a comunicação entre aplicações;
- É um padrão para envio de mensagens;
- Sua comunicação se dá na internet;
- É independente de plataforma;
- É independente de linguagem de programação;
- É baseado em XML;
- Permite passar por firewalls;
- É uma recomendação do W3C;

Atualmente as aplicações se comunicam via RPC (Remote Procedure Calls), mas o HTTP não foi desenhado para isso. RPC possui problemas de compatibilidade e segurança; firewalls e servidores de proxy normalmente bloqueiam mensagens desse tipo. Para resolver esses problemas foi criado o protocolo SOAP.

Uma mensagem SOAP é basicamente um documento XML que contém os seguintes elementos:

- Um elemento 'Envelope' que identifica o documento XML como uma mensagem SOAP;
- Um elemento 'header' que contém informações de cabeçalho;
- Um elemento 'body' que contém informações de chamadas e retornos;
- Um elemento 'Fault' que contém informações sobre erros e status;

‘ Estrutura de uma mensagem SOAP’

```
<?xml version="1.0"?>
```

```
<soap:Envelope
xmlns:soap="http://www.w3.org/2001/12/soap-envelope"
soap:encodingStyle="http://www.w3.org/2001/12/soap-encoding">

<soap:Header>
...
</soap:Header>

<soap:Body>
...
    <soap:Fault>
        ...
    </soap:Fault>
</soap:Body>

</soap:Envelope>
```

5.3 WSDL

WSDL é uma linguagem baseada em XML para localizar e descrever web services.

O WSDL (Web Services Description Language) é uma linguagem baseada em XML, com a finalidade de documentar as mensagens que o Web service aceita e gera. É uma espécie de contrato. Esse mecanismo padrão facilita a interpretação dos 'contratos' pelos desenvolvedores e ferramentas de desenvolvimento.

WSDL é:

- A linguagem padrão para descrever web services;
- É baseado em XML;
- É usado para localizar web services;
- É um padrão W3C.

Um WSDL descreve um web service usando principalmente os seguintes elementos:

Tabela 5.1: Elementos de um documento WSDL

Elemento	Descrição
<code><types></code>	Um container para a definição dos tipos de dados usados pelo web service
<code><message></code>	Definição dos dados que serão usados na comunicação
<code><portType></code>	Um conjunto de operações suportadas por um ou mais endpoints
<code><binding></code>	Um protocolo e especificação de dados para um port type específico

Abaixo temos uma fração simplificada de um documento WSDL:

‘WSDL’

```
<message name="getTermRequest">
  <part name="term" type="xs:string"/>
</message>

<message name="getTermResponse">
  <part name="value" type="xs:string"/>
</message>

<portType name="glossaryTerms">
  <operation name="getTerm">
    <input message="getTermRequest"/>
    <output message="getTermResponse"/>
  </operation>
</portType>
```

5.4 UDDI

UDDI é um serviço de diretório que permite às empresas descobrir, registrar e procurar Web services. É baseado em padrões do W3C (World Wide Web Consortium) e IETF (Internet Task Force) como XML, HTTP e DNS.

Os benefícios de se usar UDDI são muitos. Antes do UDDI não havia padrão para as empresas divulgarem seus produtos e serviços para os seus consumidores e parceiros. Com o UDDI, por exemplo, se for definido um padrão para serviços de empresas aéreas, quando as empresas publicarem os seus serviços em um diretório UDDI as agências de viagem poderão procurar por esses serviços e iniciar imediatamente a comunicação.

Capítulo 6

O Projeto

Esse capítulo descreverá a aplicação que foi desenvolvida para a realização dos testes, qual a arquitetura que foi utilizada no projeto, além de descrever os planos de testes.

6.1 A Aplicação

Para a execução dos testes de performance foi desenvolvido um Web service com as principais operações necessárias para manter os dados do AFD. O objetivo central da aplicação é manter os documentos da pasta funcional dos servidores. Como a aplicação deve armazenar arquivos, escolhemos gravar o arquivo no sistema operacional e armazenar o caminho para ele na base de dados. Na figura 6.1 temos o modelo de casos de uso e na figura 6.2 temos uma breve descrição dos métodos do Web service. O objetivo ao se escolher realizar os testes de performance via Web service foi o de flexibilizar ao máximo as implementações em diversos bancos de dados. Na tabela 6.1 a descrição das funcionalidades implementadas.

6.2 A Arquitetura do Projeto

Para cumprirmos o nosso objetivo, que é testar a nossa aplicação com diferentes bancos de dados, montamos uma arquitetura simples, mas que nos permitisse trocar as implementações da camada de persistência sem maiores esforços. Para a execução dos testes utilizamos o JMeter. A aplicação foi desenvolvida em python com o apoio do framework web2py na implementação do Web service. A linguagem de programação python foi escolhida pela facilidade de encontrar drivers de diversos bancos de dados relacionais e não relacionais, além de ser uma linguagem orientada a objetos e de ampla utilização. O framework web2py foi adicionado ao projeto pelo motivo de suportar a implementação de Web services de modo rápido e fácil, além da geração automática do WSDL (arquivo que contém a descrição das operações do Web service). A diagramação da arquitetura pode ser vista na figura 6.3

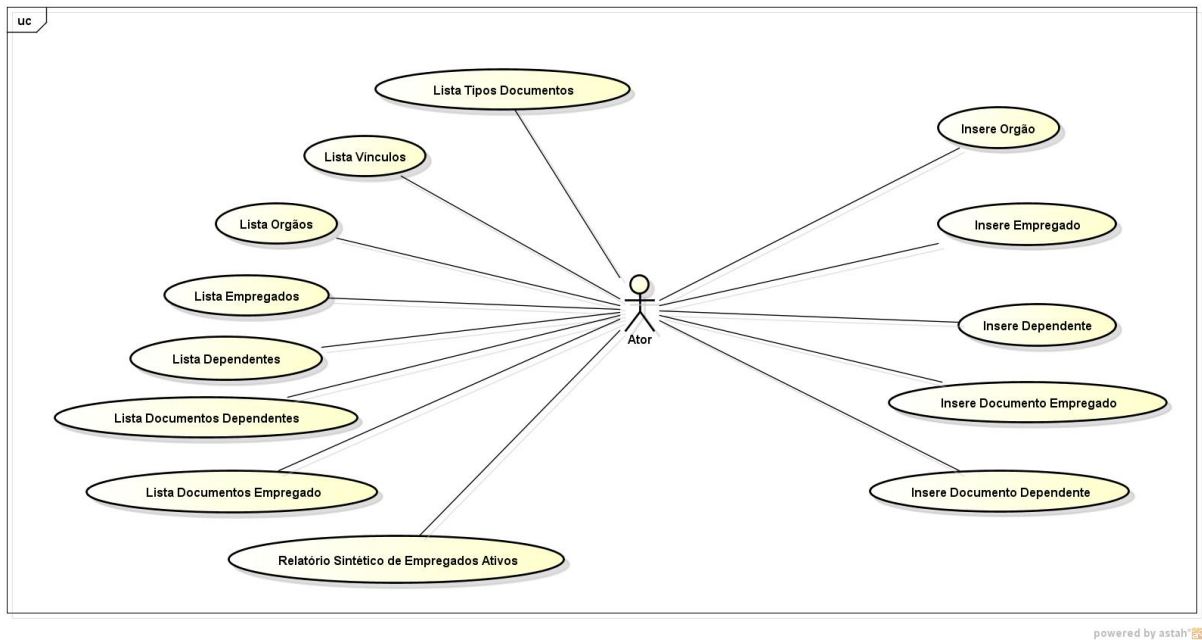


Figura 6.1: Modelo de Casos de Uso

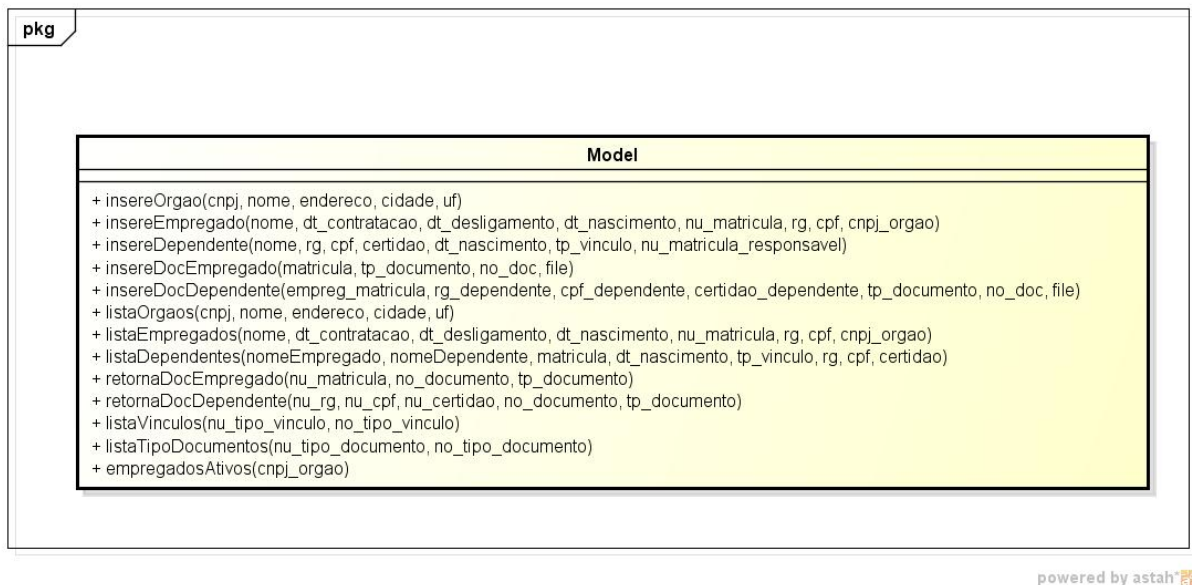


Figura 6.2: Descrição dos Métodos

Tabela 6.1: Descrição das Funcionalidades

Funcionalidade	Descrição
Inserir Órgão	Permite inserir as unidades pagadoras ou órgãos que terão os dados dos empregados mantidos no sistema.
Inserir Empregado	Permite inserir os empregados de cada órgão.
Inserir Dependente	Permite inserir os dependentes de cada empregado.
Inserir Documento Dependente	Permite inserir os documentos dos dependentes que farão parte da pasta funcional do empregado.
Inserir Documento Empregado	Permite inserir os documentos que farão parte da pasta funcional do empregado.
Lista Órgãos	Lista os dados dos órgãos cadastrados no sistema.
Lista Empregados	Lista os dados dos empregados cadastrados no sistema.
Lista Dependentes	Lista os dados dos dependentes dos empregados.
Lista Documentos Empregados	Retorna os documentos da pasta funcional do empregado.
Lista Documentos Dependentes	Retorna os documentos dos dependentes dos empregados.
Relatório Sintético de Empregados Ativos	Calcula e exibe a quantidade de empregados ativos por órgão.
Lista Vínculos	Lista os valores possíveis para os tipos de vínculos entre empregados e dependentes.
Lista Tipo Documentos	Lista os valores possíveis para os tipos de documentos.




Figura 6.3: Arquitetura de Testes

6.2.1 web2py

Web2py é um framework para desenvolvimento ágil de aplicações web, software livre e gratuito. Ele é escrito e programável em Python. [<http://www.web2py.com/>] web2py foi inspirado pelo Ruby on Rails e Django. Tem seu foco no desenvolvimento ágil e segue o MVC (Model View Controller). Toda aplicação web2py é composta por Models (arquivos que contêm a descrição dos dados), Views (arquivos que contêm a descrição dos dados que serão apresentados), Controllers (arquivos que contêm a lógica e workflow do negócio), Cron Jobs (tarefas que precisam ser executadas regularmente) e Static Files (imagens, scripts, folhas de estilos, etc.)

Quando se trata de Web services, web2py oferece suporte para diversos protocolos, incluindo XML, JSON, RSS, CSV, XMLRPC, JSONRPC, AMFRPC, e SOAP. O web2py inclui um cliente e servidor SOAP (pysimplesoap) criado por Mariano Reingart. Uma facilidade encontrada é a geração automática do WSDL e a página com a descrição dos métodos.

6.3 Os Planos de Teste

Foi desenvolvido um plano de testes no JMeter para cada funcionalidade da nossa aplicação. O testador utilizado no nosso projeto foi o de Requisição SOAP/XML - RPC. É nele que configuramos as requisições que serão feitas ao Web service da aplicação. Além de configurar uma requisição para cada plano de teste, temos como parametrizar outras configurações como a quantidade de usuários virtuais e o intervalo entre a inicialização de cada usuário. Na tabela 6.2 temos as principais configurações dos nossos planos de teste.

Tabela 6.2: Principais configurações dos Planos de Teste

Parâmetro	Descrição
Quantidade de usuários virtuais (threads)	Quanto maior o número de usuários virtuais, maior será o número de requisições simultâneas que a nossa aplicação terá que responder.
Tempo de inicialização dos usuários virtuais	Indica o tempo total para a inicialização de todos os usuários virtuais. Para encontrarmos o tempo entre a inicialização de cada usuário devemos dividir pelo total de usuários virtuais.
O local dos arquivos CSV	Esses arquivos devem ser gerados antes do início dos testes com o apóio de um script.
Intervalo de medição dos gráficos	É o intervalo de tempo em que o JMeter faz as medidas para plotar cada gráfico.

Os planos de testes desenvolvidos são basicamente de dois tipos: inserção e consulta. Sendo assim, os passos que eles executam são os mesmos.

6.3.1 Planos de Teste de Inserção

Os planos de Testes de Inserção executam os seguintes passos:

1. Configuração de Dados CSV - É indicado onde está o arquivo csv de onde as threads lerão os valores a serem enviados na requisição soap;
2. Requisição SOAP/XML-RPC - É configurada a URL do Web service e a requisição que será realizada. Cada requisição será montada com os dados lidos do arquivo csv. Cada thread lê uma linha diferente do arquivo.
3. Gráfico de Tempo de Resposta - Elemento responsável por gerar um gráfico a partir dos dados da requisição feita. O gráfico exibe a evolução do tempo de resposta das requisições feitas.

4. Gráfico de Resultados - Elemento responsável por exibir a evolução dos tempos das requisições, a média dos tempos das requisições, a derivação do tempo das requisições e a vazão.

6.3.2 Planos de Teste de Consulta

Os planos de Testes de Consulta executam os seguintes passos:

1. Requisição SOAP/XML-RPC - É configurada a URL do Web service e a requisição que será realizada. Cada requisição será montada com os dados lidos do arquivo csv. Cada thread lê uma linha diferente do arquivo.
2. Gráfico de Tempo de Resposta - Elemento responsável por gerar um gráfico a partir dos dados da requisição feita. O gráfico exibe a evolução do tempo de resposta das requisições feitas.
3. Gráfico de Resultados - Elemento responsável por exibir a evolução dos tempos das requisições, a média dos tempos das requisições, a derivação do tempo das requisições e a vazão.

Capítulo 7

Execução dos Testes

Nesse capítulo vamos descrever o ambiente onde os testes foram realizados, as métricas que foram escolhidas para medir a performance e os resultados obtidos.

7.0.3 Ambiente de testes

Os testes foram realizados em uma máquina virtualizada, via VirtualBox, com as seguintes configurações:

- Sistema Operacional: Debian GNU/Linux 6.0
- Quantidade de Processadores: 1
- Quantidade de Memória RAM: 2048 MB
- Capacidade do HD: 60 GB
- Mongo DB: Versão 2.4.0 com configurações padrão
- PostgreSQL: Versão 8.4.16

7.0.4 Massa de Dados

Conforme Molyneaux diz [26], a importância de prover a quantidade de dados de qualidade para um teste não pode ser exagerada. Segundo ele a quantidade e a qualidade dos dados podem definir o sucesso ou insucesso dos testes. Para o nosso projeto foi desenvolvido um script em python para a geração da massa de dados. Os dados podem tanto ser inseridos diretamente na base de dados quanto em arquivos CSV que serão utilizados durante os testes. Os arquivos utilizados nos testes possuem tamanho médio de 400 KB. A quantidade de dados gerados também pode ser configurada pelo seguinte:

1. Quantidade de Unidades Pagadoras (Orgãos);
2. Quantidade de empregados por órgão;
3. Quantidade de dependentes por empregado;
4. Quantidade de documentos por empregado;
5. Quantidade de documentos por dependente;

7.0.5 Métricas

Quando se quer balancear o custo e a performance, todos os envolvidos na produção do software se preocupam com a execução de testes de performance. A avaliação de performance é necessária em todas as etapas do ciclo de vida de software e é requerida sempre que o arquiteto precisa comparar alternativasv [23]. Em um teste de performance a escolha das métricas é de grande importância. Segundo Raj Jain [23], escolher as métricas erradas é um dos erros mais comuns. Para o nosso trabalho as métricas escolhidas foram a vazão e o tempo de resposta.

7.0.6 Resultados

Referências

- [1] Apache jmeter. <http://jmeter.apache.org>. Acessado em 02 de julho de 2013. vii, 27
- [2] Apresentação - assentamento funcional digital. www.sigepe.gov.br/assentamento-funcional-digital/apresentacao-assentamento-funcional-digital. Acessado em 23 de Abril de 2013. 3
- [3] Emc digital universe. <http://www.emc.com/collateral/demos/microsites/emc-digital-universe-2011/index.htm>. Acessado em 26 de Janeiro de 2013. 4
- [4] História do hdl. <http://www.dicasparacomputador.com/>. Acessado em 02 de julho de 2013. vii, 2
- [5] Mongodb official site. <http://www.mongodb.org/>. Acessado em 27 de Janeiro de 2013. vii, viii, 14, 15, 16, 17, 18, 19, 20, 21
- [6] Msdn - classe web services. <http://msdn.microsoft.com/pt-br/library/cc564893.aspx>. Acessado em 25 de junho de 2013. 31
- [7] nosql database org. <http://nosql-database.org/>. Acessado em 09 de Dezembro de 2012. 12, 13, 14
- [8] Recomendações para digitalização de documentos arquivísticos permanentes. <http://www.emc.com/collateral/demos/microsites/emc-digital-universe-2011/index.htm>. Acessado em 23 de Abril de 2013. 1, 2
- [9] Sigepe.org. www.sigepe.gov.br. Acessado em 23 de Abril de 2013. 3
- [10] Testlink. <http://testlink.sourceforge.net/>. Acessado em 02 de julho de 2013. vii, 26
- [11] K. Bakshi. Considerations for big data: Architecture and approach. In *Aerospace Conference, 2012 IEEE*, pages 1–7, march 2012. 6
- [12] D. Bollier, Communications, and Society Program (Aspen Institute). *The Promise and Peril of Big Data*. Aspen Institute, Communications and Society Program, 2010. 5
- [13] Vinayak R. Borkar, Michael J. Carey, and Chen Li. Big data platforms: What's next? *XRDS*, 19(1):44–49, 2012. 1, 4
- [14] Ricardo W. Brito. Banco de dados NoSQL x SGBDs relacionais: Análise comparativa. 2010. 11, 13

- [15] Rick Cattell. Scalable sql and nosql data stores. *SIGMOD Rec.*, 39(4):12–27, May 2011. 8
- [16] Andrew Cron, Huy L. Nguyen, and Aditya Parameswaran. Big data. *XRDS*, 19(1):7–8, 2012. 1
- [17] Ramez Elmasri and Shamkant B. Navathe. *Sistemas de Banco de dados*. Pearson Addison Wesley, 6 edition, 2011. 6
- [18] Benjamin Erb. Concurrent programming for scalable web architectures. Diploma thesis, Institute of Distributed Systems, Ulm University, April 2012. vii, 8
- [19] Gartner. Big data. <http://www.gartner.com/it-glossary/big-data/>. Acessado em 14 de Dezembro de 2012. 4
- [20] Jing Han, E. Haihong, Guan Le, and Jian Du. Survey on nosql database. In *Pervasive Computing and Applications (ICPCA), 2011 6th International Conference on*, pages 363 –366, oct. 2011. 13
- [21] R. Hecht and S. Jablonski. Nosql evaluation: A use case oriented survey. In *Cloud and Service Computing (CSC), 2011 International Conference on*, pages 336 –341, dec. 2011. 7, 11, 12, 13, 14
- [22] E. Hewitt. *Cassandra: The Definitive Guide*. Definitive Guide Series. O’Reilly Media, 2010. 7
- [23] Raj Jain. *The art of computer systems performance analysis - techniques for experimental design, measurement, simulation, and modeling*. Wiley professional computing. Wiley, 1991. 42
- [24] N. Leavitt. Will nosql databases live up to their promise? *Computer*, 43(2):12 –14, feb. 2010. 6, 12
- [25] Sam Madden. From databases to big data. *Internet Computing, IEEE*, 16(3):4 –6, may-june 2012. 4, 5
- [26] Ian Molyneaux. *The Art of Application Performance Testing - Help for Programmers and Quality Assurance*. O’Reilly, 2009. 25, 41
- [27] Kai Orend. Analysis and classification of nosql databases and evaluation of their ability to replace an object-relational persistence layer, 2010. vii, 6, 8, 9, 10, 15, 16, 17, 18
- [28] E. Rios and T. MOREIRA. *Teste de software*. Alta Books, 2006. 23, 26
- [29] Cezar Taurion. Big data = volume + variedade + velocidade. <https://www.ibm.com/developerworks>, 2012. Acessado em 14 de Dezembro de 2012. 4
- [30] Cezar Taurion. Você realmente sabe o que é big data? <https://www.ibm.com/developerworks>, 2012. Acessado em 14 de Dezembro de 2012. 2

- [31] S. Tiwari. *Professional NoSQL*. Wrox Programmer to Programmer. Wiley, 2011. 14
- [32] Guoxi Wang and Jianfeng Tang. The nosql principles and basic application of cassandra model. In *Computer Science Service System (CSSS), 2012 International Conference on*, pages 1332–1335, 2012. 8, 9